Scikit-learn

사이킷런이란?

- 파이썬 머신러닝 라이브러리
- 머신러닝을 위한 다양한 알고리즘 제공
- 편리한 개발 프레임워크

사이킷런 기반 프레임워크

Estimator

지도학습 Estimator 종류

1. classifier- 분류
2. regressor- 회귀

- 사이킷런에서 머신러닝 알고리즘을 구현한 클래스의 총칭
- 모든 Estimator는 공통 API 사용

주요 메서드

- fit() - 모델 학습
- predict() - 학습된 모델로 예측

example

- cross_val_score()
- GridSearchCV

비지도 학습 API

- fit() - 데이터 구조 학습
- transform() - 데이터 변환
- fit_transform() - fit + transform

사이킷런 주요 모듈

- 데이터: sklearn.datasets
- 데이터 전처리: sklearn.preprocessing
- 피처 처리: sklearn.feature_selection/ sklearn.feature_extraction
- 차원 축소: sklearn.decomposition

- 주요 알고리즘

sklearn.ensemble

sklearn.linear_model

sklearn.naive_bayes

sklearn.neighbors

sklearn.svm

sklearn.tree

sklearn.cluster

데이터셋 구조

주요 key

- data 피처 데이터
- target 레이블
- target_names 레이블 이름
- feature_names 피처 이름

Model Selection 모듈

sklearn.model_selection

주요 기능

1. train_test_split()
    a. 데이터를 학습 데이터 + 테스트 데이터로 분리
2. cross validation 교차 검증
    a. K-Fold cross validation

       ex. 5 Fold → 데이터 5개로 분할

       1회: 4개 학습 + 1개 검증
       2회: 다른 1개 검증
       ...
       5회 반복

       평균 정확도 계산
    b. stratified K-Fold

       원본 데이터의 클래스 비율 유지 → KFold의 문제 해결
    c. cross_val_score()

       교차 검증을 한 줄로 실행하는 함수

       cross_val_score(estimator, X, y, scoring, cv)

3. GridSearchCV

   하이터파라미터 자동 최적화

   *하이퍼파라미터: 모델 성능에 영향을 주는 설정값

   파라미터 설정

   parameters = {
   'max_depth': [1,2,3],
   'min_samples_split': [2,3]
   }

   GridSearchCV 코드

   grid_dtree = GridSearchCV(
   dtree,

```
param_grid=parameters,
cv=3,
refit=True
)
```

```
{'max_depth':3, 'min_samples_split':2}
```

데이터 전처리

1. 결손값 처리
2. 문자열 → 숫자 인코딩
3. 피처 스케일링

1. 결손값

NaN/Null 값 허용x

처리방안

- 결손값 적음 → 평균값 등으로 대체
- 결손값 많음 → 해당 피처 삭제
- 중요한 피처면 업무 로직을 고려해 대체값 설정

2. 문자열 데이터 처리

문자열 데이터를 입력값으로 사용할 수 없음 → 숫자 형태로 변환

문자열 피처 종류

- 카테고리형
- 텍스트형
- 식별자

3. 데이터 인코딩

1. 라벨 인코딩: 카테고리 값을 숫자로 변환

   ! 숫자 크기의 의미가 생김 → 회귀에 부적합

2. 원 핫 인코딩: 카테고리를 별도의 컬럼으로 생성

   해당 컬럼 1

   나머지 0

4. 피처 스케일링

1. 표준화

   평균 0 분산1 로 변환

2. 정규화

   데이터를 0 ~ 1 사이 값으로 변환